


### Exercice 1:

- ① soit  $(p_i)_i$  tels que  $\sum_{i=1}^n p_i = 1$ ,  $P(X=x_i) = p_i$ .  
utilisons la fonction de répartition de  $X$ .

$$F_X(x) = P(X \leq x) = \sum_{i=1}^x p_i.$$

On obtient une fonction de la sorte:



pour simuler  $X$  selon les  $(p_i)_i$ , on tire  $U \sim U[0,1]$ . On note  $u$  le tirage.

$\forall i \in \{1, \dots, n\}$ , si  $p_{i-1} \leq u \leq p_i$ , on simule  $X = x_i$ .

- ② pseudo-code :

simuler  $U \sim U[0,1]$

cum-prob  $\leftarrow$  cumsum( $p$ )

for  $i$  in range( $n$ )

si cumprob[ $i$ ]  $\leq u \leq$  cumprob[ $i+1$ ]:  
return  $x(i)$



Exercice 2 : (Notations :  $X \sim \mathcal{N}(\mu, \Sigma)$ ,  $f_X(x) = \mathcal{N}(x; \mu, \Sigma)$ )

② En utilisant les notations de l'énoncé,  $\forall j \in \{1, \dots, m\}$   
 $\theta_j = (\alpha_j, \mu_j, \Sigma_j)$ . (paramètres du modèle)

Calculons la vraisemblance de  $(\theta, x_1, \dots, x_n)$  :

$$\mathcal{L}(x_1, \dots, x_n, \theta) = \prod_{i=1}^n f_{\theta}(x_i) = \prod_{i=1}^n p(x_i | \theta)$$

$$\forall i \in \{1, \dots, n\}, \quad p(x_i | \alpha, \mu, \Sigma) = \sum_{z_i} p(x_i, z_i | \alpha, \mu, \Sigma)$$

$$\text{or, } p(x_i, z_i | \theta) = p(x_i | z_i, \mu, \Sigma) p(z_i | \alpha)$$

$$\text{et } p(x_i | z_i, \mu, \Sigma) = \prod_{j=1}^m \mathcal{N}(x_i; \mu_j, \Sigma_j)^{z_{ij}}$$

$$\text{donc } p(x_i, z_i | \alpha, \mu, \Sigma) = \prod_{j=1}^m \alpha_j \mathcal{N}(x_i; \mu_j, \Sigma_j)^{z_{ij}}$$

$$\text{d'où } p(x_i | \alpha, \mu, \Sigma) = \sum_{z_i} \left[ \prod_{j=1}^m \alpha_j \mathcal{N}(x_i; \mu_j, \Sigma_j)^{z_{ij}} \right]$$

$$\begin{aligned} &= \alpha_1 \mathcal{N}(x_i; \mu_1, \Sigma_1) + \alpha_2 \mathcal{N}(x_i; \mu_2, \Sigma_2) + \dots + \alpha_m \mathcal{N}(x_i; \mu_m, \Sigma_m) \\ &= \sum_{j=1}^m \alpha_j \mathcal{N}(x_i; \mu_j, \Sigma_j) \end{aligned}$$

Finalement, on obtient :

$$\begin{aligned} \mathcal{L}(x_1, \dots, x_n, \theta) &= \prod_{i=1}^n \sum_{j=1}^m \alpha_j \mathcal{N}(x_i; \mu_j, \Sigma_j) \\ &= \prod_{i=1}^n \sum_{j=1}^m \frac{\alpha_j}{\sqrt{2\pi |\Sigma_j|}} e^{-\frac{1}{2}(x_i - \mu_j)' \Sigma_j^{-1} (x_i - \mu_j)} \end{aligned}$$

□



$$\textcircled{3} \forall (i, j) \in \{1, \dots, n\} \times \{1, \dots, m\},$$

$$\gamma_{ij} = \frac{\alpha_j \mathcal{N}(x_i; \mu_j, \Sigma_j)}{\sum_{l=1}^m \alpha_l \mathcal{N}(x_i; \mu_l, \Sigma_l)}$$

calculs de  $\hat{\alpha}, \hat{\mu}, \hat{\Sigma}$  (par rapport aux  $\gamma_i$ )

$\forall j \in \{1, \dots, m\}$

$$\begin{cases} \hat{\alpha}_j = \frac{1}{n} \sum_{i=1}^n \gamma_{ij} \\ \hat{\mu}_j = \frac{1}{n_j} \sum_{i=1}^n \gamma_{ij} x_i \quad (n_j: \text{number of observa}^\circ \text{ in cluster } j) \\ \hat{\Sigma}_j = \frac{1}{n_j} \sum_{i=1}^n \gamma_{ij} (x_i - \hat{\mu}_j)(x_i - \hat{\mu}_j)^T \end{cases} \quad n_j = \sum_{i=1}^n \gamma_{ij}$$

Une fois EM exécuté,  
 $\textcircled{4}$  la prédiction des paramètres  $\alpha, \mu$  et  $\Sigma$  sont assez proches des paramètres réels. Ces résultats sont illustrés dans le notebook.

### $\textcircled{5}$ Application :

Après observation des données en 2D, la distribution ne ressemble pas à un ~~mêl~~ modèle de mélange gaussien (pas d'observation de clusters ni de ballon de rugby (forme d'une gaussienne en 2 dimensions)).



### Exercice 3:

③ Pour  $\mu=0,8$ , l'estimation  $E[f(x)]$  est bonne, alors que pour  $\mu=6$ , beaucoup de poids sont des 0, et la variance est plus élevée. (voir notebook)

④. dans EM pour un modèle de mélange gaussien, la vraisemblance à maximiser (avant l'ajout des variables latentes  $z_i$ ) est:

$$\mathcal{L}(x_1 \dots x_n, \theta) = \prod_{i=1}^n \sum_{j=1}^m \alpha_j \mathcal{N}(x_i; \mu_j, \Sigma_j)$$

en prenant la log-vraisemblance:

$$\ell(x_1 \dots x_n, \theta) = \sum_{i=1}^n \log \sum_{j=1}^m \alpha_j \mathcal{N}(x_i; \mu_j, \Sigma_j)$$

Dans le Population Monte Carlo Algorithm, nous devons maximiser:

$$\sum_{i=1}^n \tilde{w}_i \log \sum_{j=1}^m \alpha_j \mathcal{N}(x_i; \mu_j, \Sigma_j) \quad (1)$$

pour EM, maximiser  $\ell(x_1, \dots, x_n, \theta)$  revient à maximiser

$$E_z \left[ \ell(x_1, \dots, x_n, z_1, \dots, z_n, \theta) \right] = \sum_{i=1}^n \sum_{j=1}^m \gamma_{ij} \log(\alpha_j \mathcal{N}(x_i; \mu_j, \Sigma_j))$$

et EM assure que ceci converge.

De la même manière, on obtient pour (1):

$$\sum_{i=1}^n \sum_{j=1}^m \tilde{w}_i \gamma_{ij} \log(\alpha_j \mathcal{N}(x_i; \mu_j, \Sigma_j)) \quad (2)$$

donc par propriété, EM permet d'assurer que ceci converge.

Nous pouvons donc utiliser EM pour maximiser (1).

Dans ce cas,  $\forall i \in \{1, \dots, n\}$ ,  $\forall j \in \{1, \dots, m\}$ ,  $\gamma_{ij}$  devient  $w_i \gamma_{ij}$ .

(2)

On peut retrouver grâce à ça les nouvelles valeurs des paramètres  $\alpha$ ,  $\mu$  et  $\Sigma$ .

$$\frac{\partial \ell(2)}{\partial \mu_j} = \frac{\partial}{\partial \mu_j} \left( \sum_{i=1}^m \tilde{w}_i \sum_{j=1}^m \gamma_{ij} \left( \log \alpha_j + \log \left( -\frac{1}{2} (x_i - \mu_j)^T \Sigma_j^{-1} (x_i - \mu_j) \right) \right) \right)$$
$$= \sum_{i=1}^m \tilde{w}_i \gamma_{ij} \frac{x_i - \mu_j}{\Sigma_j} = 0$$

$$\Rightarrow \sum_{i=1}^m \tilde{w}_i \gamma_{ij} x_i = \sum_{i=1}^m \tilde{w}_i \gamma_{ij} \mu_j$$

$$\Rightarrow \boxed{\hat{\mu}_j = \frac{\sum_{i=1}^m \tilde{w}_i \gamma_{ij} x_i}{\sum_{i=1}^m \tilde{w}_i \gamma_{ij}}}$$

De la même manière, avec les mêmes types de calculs que EM pour les modèles de mélange gaussiens, on obtient :

$$\boxed{\hat{\Sigma}_j = \frac{\sum_{i=1}^m \tilde{w}_i \gamma_{ij} (x_i - \mu_j)^2}{\sum_{i=1}^m \tilde{w}_i \gamma_{ij}}}$$

et

$$\boxed{\hat{\alpha}_j = \frac{1}{n} \sum_{i=1}^m w_i \gamma_{ij}}$$

□